Modélisation DataWarehouse

RAPPEL (1/4)

- Datawarehouse ou entrepôt de données : vision centralisée et universelle de toutes les informations de l'entreprise
- DataMart : division d’un datawarehouse par fonction (vente, commande, ressource humaines, …) ou par sous-ensemble (un datamart par succursale)

RAPPEL (2/4)

- Dimension : axe avec lequel on veut faire l'analyse (client, produit, géographie, temps, …)
- Fait : ce qu'on voudra analyser (CA net, quantité, performance employé, nombre de démission, …)
- ETL: outil qui permet de récupérer les données opérationnels vers le datawarehouse

RAPPEL (3/4)

- Modélisation étoile: une façon de mettre en relation les dimensions et les faits

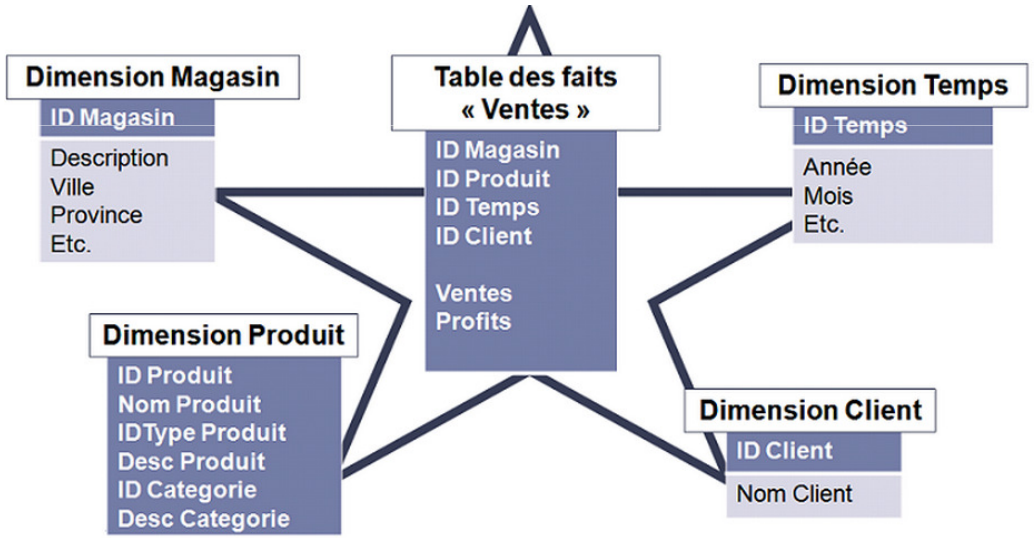

RAPPEL (4/4)

- Modélisation flocon : modèle de mise en relation des dimensions et des faits mais avec des hiérarchies dans les dimensions

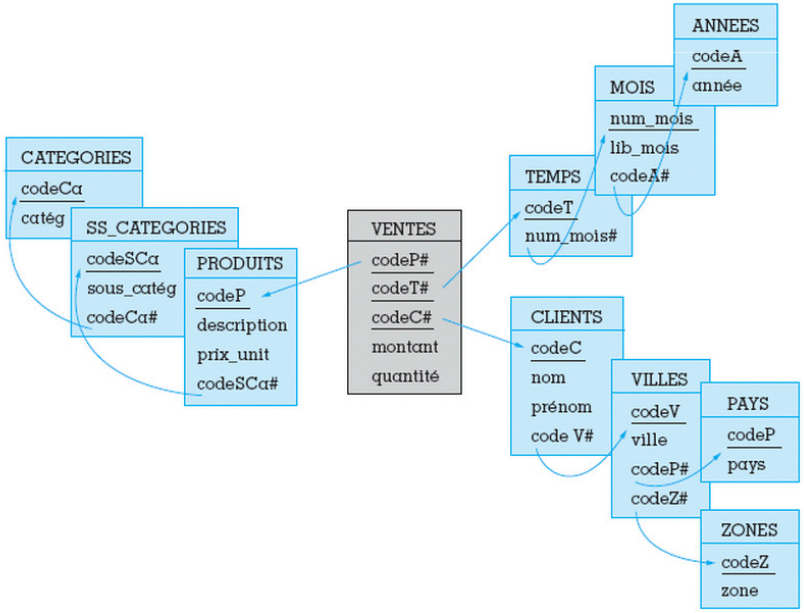

ETUDE DE CAS

- On vous demande de créer un datamart (modélisation étoile) pour l'analyse de l'activité des représentants d'une entreprise de vente d'imprimantes.
- Besoin du chef entreprise
  - Les employés font ils leur travail?
  - Quelle est la zone de couverture des vendeurs?
  - Où sont les endroits où les vendeurs sont le moins efficaces?
  - Quelle est la moyenne de ventes des représentants?
  - Etc ….
- Données à disposition
  - Système de gestion de ressources humaines
  - Un système de gestion des ventes et des feuilles de routes avec des informations concernant les vendeurs :
    - kilomètres parcourus,
    - litres d'essence utilisée,
    - frais de voyage,
    - ventes, promesses de ventes, etc.

ANALYSE

- Notre objectif est d'analyser l'activité des représentants. Toutes les informations sont disponibles mais dans différents systèmes.
- Objectifs:
  - Identifier les axes d'analyse
  - Identifier les éléments à analyser
- Démarches :
  - Etude de ce qui se passe dans l'entreprise (document échangés, rapport périodiques, etc…)
  - Se mettre à la place de chaque utilisateur (analyste, décideur …)

RÉSULTAT DE L'ANALYSE

- Le tableau suivant a été rempli pendant la phase d'analyse, en posant des questions aux décideurs du type :

	Date	Vendeur	Produit	Zone géographique	Client
	Années	Nom	Catégorie	Pays	Nom
	Mois	Prénom	Type	Province	Adresse
	Jours	Salaire	Groupe	Ville	Pays
	Heures				
Analyse : consommation d'essence, Qte commandée, Qte précommandée, kilométrage, nombre de visites, etc.					

  - Que voulez vous analyser (la dernière ligne du tableau) ?
  - Quels sont vos critères d'analyse (la première ligne du tableau) ?
  - Jusqu'à quel niveau de détail voulez vous aller (les cellules è l'intérieur) ?
- Remarque : L'axe du temps (dimension Temps) est toujours présent dans un entrepôt de données, c'est le type d'analyse le plus commun et le plus fréquent en entreprise.

PRÉPARATION MODÉLISATION (1/2)

- La structure d'un entrepôt étant plus rigide que les systèmes conventionnels (se basent sur des ETL, des validations créées par l'homme, etc.), il est capital d'avoir une analyse des besoins exhaustive et conforme aux attentes des décideurs.
- Il faut savoir :
  - D'où provient chaque champ ?
  - Comment transite l'information ?
  - Où trouver l'information voulue?

PRÉPARATION MODÉLISATION (2/2)

- Se poser des questions du type :
  - Ai-je assez de données pour répondre aux besoins ?
  - Si non, qu'est ce que cela impliquerait de les créer ?
  - Comment alimenter mes dimensions ?
  - Comment alimenter mes faits ?
  - Comment valider mes chargements ?
  - Etc., etc., etc.
- Vous pouvez penser que c'est de la paranoïa et croire que tous ces problèmes n'apparaîtront pas forcément. Mais rappelez vous qu'un entrepôt ça coûte très cher, et qu'un entrepôt avec des données incomplètes, invalides ou non-conformes à la demande est tout simplement à mettre à la poubelle…

MODÉLISATION EN ÉTOILE (1/3)

- La table de fait contient se qu'on appelle des " mesures ", des champs (numériques pour la plupart) sur lesquels on va faire nos analyses, on peut y trouver :
  - le montant des ventes nettes, les quantités vendues, les kilomètres parcourus, les quantités en pré commande, etc.
- La table de faits est reliée aux dimensions par des relation (1, n). Pour analyser une ligne de fait par client par exemple, il faut qu'il y ait une relation entre cette ligne et la dimension client.

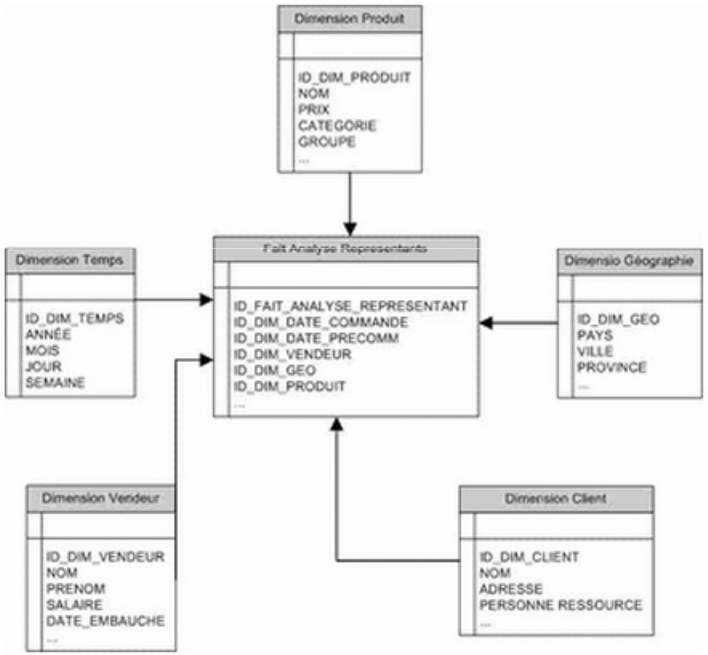

Schéma en étoile

MODÉLISATION EN ÉTOILE (2/3)

- Les tables de dimension contiennent les éléments qu'utiliseront les décideurs pour voir la table de faits.
- Les utilisateurs pourront ainsi apprécier les montant des ventes par vendeur, par client, ou le kilométrage pour un vendeur pour un client donnée (pour voir si ce client est rentable), calculer le coût de revient d'un produit par rapport aux activités des vendeurs, etc.

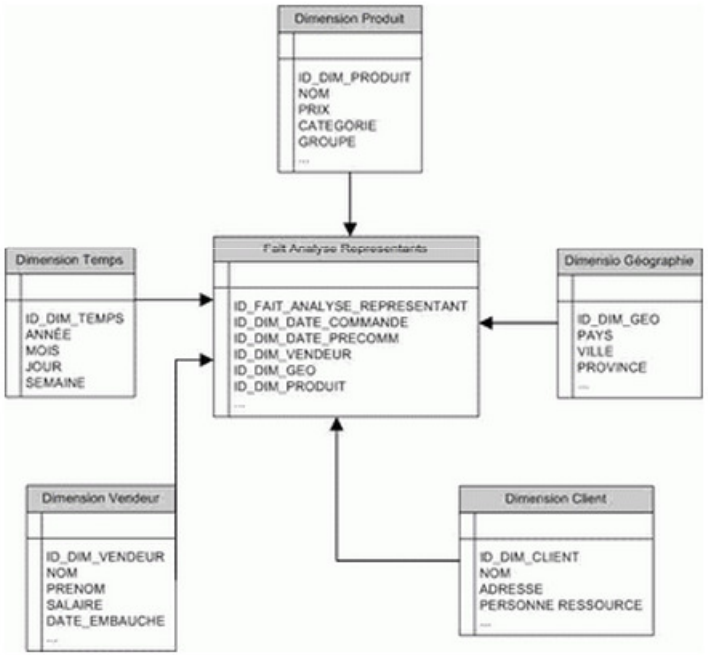

Schéma en étoile

MODÉLISATION EN ÉTOILE (3/3)

- On n'utilise JAMAIS la clé d'un système de production comme clé de dimension : pour préserver l'historique des modifications dans l'entrepôt de données
- La granularité des tables de dimensions et de faits doit être la même : imaginez que la table de faits regroupe les informations par heures et que la table de dimension du temps gère les minutes, il ne sera pas possible de lier la dimension temps et la table de faits (multi détermination).
- Chaque ligne de la table de faits doit avoir une relation avec chacune des tables de dimensions : dans le cas contraire, on aurait perte d'information ou analyse erronée.
- Il n'existe de relations qu'entre les dimensions et les tables de faits. Il sera beaucoup trop compliqué de gérer et d'utiliser des dimensions liées entre elles. N'oubliez pas que le schéma doit être assimilable par des non informaticiens pour pouvoir l'exploiter. N'ayons pas peur de créer des doublons !

MODÉLISATION EN FLOCON (1/2)

- La modélisation en flocon étant une variante de la modélisation en étoile, nous prendrons le même cas avec la même analyse.
- Il faut savoir que la modélisation en flocon existe pour des raisons de performances. En effet, des dimensions de plusieurs millions de lignes peuvent poser des problèmes de lenteur lors de l'exploitation des données.

- Le principe de la modélisation en flocon est de créer des hiérarchies de dimensions, de telle manière à avoir moins de lignes par dimensions.
  Cela va en contradiction avec la dernière remarque de la modélisation en étoile, sauf que c'est la seule façon que les gens ont trouvée pour avoir des résultats clairs et rapides.

MODÉLISATION EN FLOCON (2/2)

- Pour garder une structure simple, gérable et compréhensible, utilisez le plus possible la modélisation en étoile. La modélisation en flocon n'intervenant que lorsque des problèmes de performances apparaissent
- Une règle informelle en BI préconise de floconner que si l'on a la relation (1-1000). C'est-à-dire que si l'on réussit à créer une hiérarchie de deux dimensions avec une ligne de la dimension père (groupe produit par exemple) faisant référence à plus de 1000 lignes de la dimension fille (produit par exemple). Dans ce cas, il est peut être temps de penser aux flocons.
- Note: cette règle fût émise en prenant en considération les technologies logicielles et matérielles actuelles. Mais avec les avancées technologiques (rapidité des disques durs, technologies OLAP, etc.), on risque de voir disparaitre la modélisation en flocon

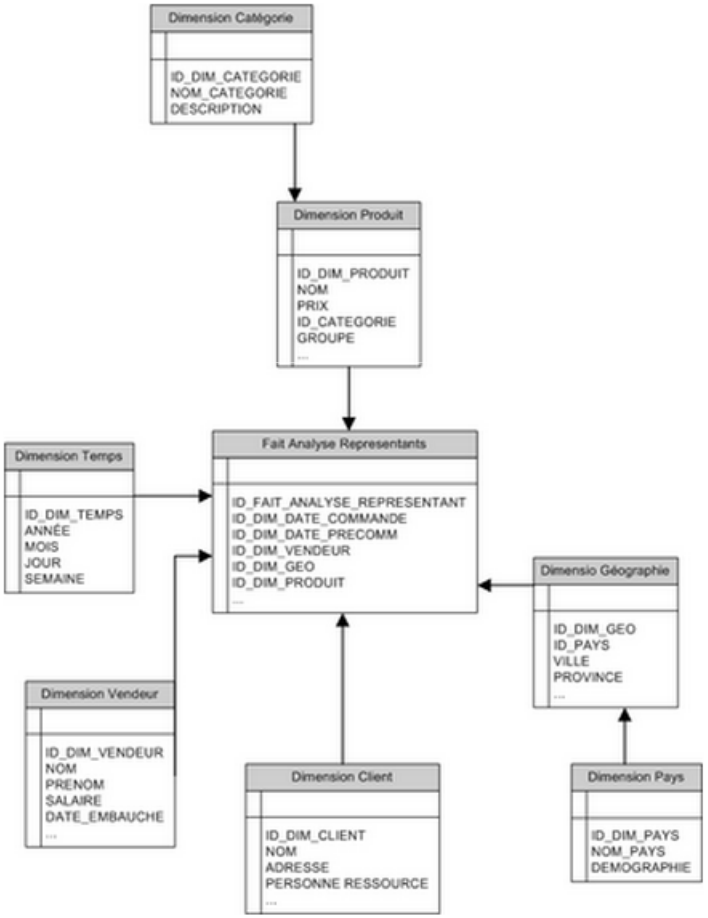

RÉCAPITULATION

- Comment créer le datawarehouse à partir d'une étoile/flocon
  - **Top-Down :** c'est la méthode la plus lourde, la plus contraignante et la plus complète en même temps. Elle consiste en la conception de tout l'entrepôt (ie : toutes les étoiles), puis en la réalisation de ce dernier. Imaginez le travail qu'une telle méthode implique : savoir à l'avance toutes les dimension et tous les faits de l'entreprise, puis réaliser tout ça… Le seul avantage que cette méthode comporte est qu'elle offre une vision très claire et très conceptuelle des données de l'entreprise ainsi que du travail à faire.
  - **Bottom-Up :** c'est l'approche inverse, elle consiste à créer les étoiles une par une, puis les regrouper par des niveaux intermédiaires jusqu'à obtention d'un véritable entrepôt pyramidal avec une vision d'entreprise. L'avantage de cette méthode est qu'elle est simple à réaliser (une étoile à la fois), l'inconvénient est le volume de travail d'intégration pour obtenir un entrepôt de données ainsi que la possibilité de redondances entre les étoiles (car elles sont faites indépendamment les unes des autres).
  - **Middle-Out :** c'est l'approche hybride, et conseillée par les professionnels du BI. Elle consiste en la conception totale de l'entrepôt de données (ie : concevoir toutes dimensions, tous les faits, toutes les relations), puis créer des divisions plus petites et plus gérables et les mettre en œuvre. Cela équivaut à découper notre conception par éléments en commun et réaliser les découpages un par un. Cette méthode tire le meilleur des deux précédentes sans avoir les contraintes. Il faut juste noter que cette méthode implique, parfois, des compromis de découpage (dupliquer des dimensions identiques pour des besoins pratiques).

CONCLUSION

- Pour voir si votre conception est bonne :
  - Votre entrepôt de données permettra de faire toutes les opérations analytiques et donnera aux décideurs des moyens chiffrés pour évaluer les faits voulus.
  - Vos dimensions seront orientées entreprise et pas fonction, avoir le plus possible des dimensions génériques et réutilisables.
  - Pas trop de flocons dans votre entrepôt, si c'est le cas, pensez plutôt à changer de serveur ou de moteur de stockage. C'est plus une technique d'optimisation que de conception.
  - Avoir des noms d'attributs et de tables compréhensibles par les utilisateurs.
  - Documenter, documenter, documenter. N'oubliez pas qu'un entrepôt non documenté est un entrepôt qu'on ne peut pas faire évoluer, comprendre ou modifier. Gare à la rétention d'information !!
  - N'oubliez pas, pendant votre phase d'analyse, de lister les outputs et les questionnements des analystes et décideurs de votre entreprise. Ceux-ci serviront de fil conducteur tout au long de votre projet.